

IA PARA PROBABILIDADE DE ALAGAMENTOS NO BUTANTÃ
SISTEMAS DE CONTROLE E INTELIGÊNCIA ARTIFICIAL

Gustavo Da Silva Hossein - 821148931

Izabelle Silva de Souza - 821144894

João Pedro Silva de Oliveira - 821225047

Nathalia Cabral Rodrigues de Almeida - 823130648

Ricardo Brito Ponticceli Prieto - 821129414

São Paulo

2025

Sumário

1. Introdução	3
2. Objetivo	4
2.1 Objetivo geral	4
2.2 Objetivos específicos	4
3. Fundamentos teóricos.....	5
3.1 Inundações urbanas, drenagem e previsibilidade.....	5
3.2 Intensidade de chuva, limiares e classes de risco	5
3.3 Dados pluviométricos, séries temporais e índice API	6
3.4 Algoritmos de aprendizado de máquina: Regressão Logística e Random Forest	7
3.5 Desbalanceamento de classes e oversampling	7
4. Materiais e Métodos	8
4.1 Área de estudo	8
4.2 Fontes de dados	8
4.3 Pré-processamento da chuva (CGE Butantã)	9
4.4 Dataset do modelo de 3 classes (risco por chuva)	9
4.5 Construção das labels com ocorrência de alagamento (GeoSampa + CGE).....	10
4.6 Filtragem para dias chuvosos e features do modelo binário	10
4.7 Oversampling e treino dos modelos binários.....	11
5. Discussão	11
5.1 Por que dois modelos?	11
5.2 Dificuldade intrínseca de prever alagamentos.....	12
5.3 Ganhos e limitações dos resultados	12
5.4 Dados adicionais que poderiam melhorar a acurácia	13
5.5 Aspectos didáticos e narrativos do projeto.....	13
6. Encerramento	14
Referências.....	14

1. Introdução

As inundações urbanas em grandes cidades brasileiras, como São Paulo, sempre foram um problema frequente que faz parte das nossas vidas, sendo resultado da combinação entre mudanças climáticas, urbanização acelerada e infraestrutura de drenagem muitas vezes insuficiente. Diversos estudos apontam tanto para o aumento na média anual de chuva quanto para a maior recorrência de eventos extremos, como dias com mais de 80–100 mm de precipitação em 24 horas na capital paulista. Esse cenário se traduz em prejuízos materiais, impactos na mobilidade urbana, riscos à saúde e à vida da população.

Apesar disso, prever com precisão quando e onde um alagamento vai ocorrer é um problema notoriamente difícil. Não basta chover “muito”: o resultado depende de uma série de fatores locais, como a capacidade hidráulica das galerias de drenagem, o estado de manutenção de bocas de lobo e bueiros, a presença de lixo e entulho nas ruas, o grau de impermeabilização do solo e a ocupação de áreas naturalmente sujeitas a inundações, como várzeas e fundos de vale. Em geral, essas informações não aparecem de forma estruturada em bases públicas abertas, o que limita fortemente qualquer modelo puramente estatístico ou de aprendizado de máquina.

Diante desse contexto, este trabalho desenvolve um protótipo de sistema de Inteligência Artificial para predição de risco de inundação no bairro do Butantã, na cidade de São Paulo, utilizando exclusivamente dados públicos. A opção por focar em uma região específica traz ganhos importantes: reduz a necessidade de calibrar tipos de solo e diferentes usos do território em várias bacias ao mesmo tempo; permite trabalhar com um único posto pluviométrico (CGE Butantã) e com uma camada consolidada de ocorrências de alagamento (GeoSampa); e viabiliza a construção de um protótipo funcional dentro do tempo e do escopo da disciplina.

Ao longo do desenvolvimento ficou evidente que não há dados suficientes atualmente para treinar um modelo robusto que preveja diretamente a ocorrência de alagamentos com base apenas na chuva. Além de os eventos serem raros, a própria natureza do fenômeno é altamente condicionada por fatores externos de infraestrutura, manutenção e ocupação urbana. Essa constatação levou à adoção de duas abordagens complementares, com papéis bem definidos:

Um modelo de três classes de risco de inundação por intensidade de chuva, baseado em faixas de precipitação diária (chuva acumulada em 24 horas).

Um modelo binário condicionado a dias chuvosos, treinado com ocorrências reais de alagamento do GeoSampa e com a chuva registrada pelo CGE, utilizando engenharia de atributos e oversampling para lidar com o desbalanceamento extremo entre dias com e sem evento.

Ambos os modelos foram encapsulados em protótipos de interface utilizando Streamlit, compondo um projeto didático de sistema de alerta local de risco de inundação para o Butantã.

2. Objetivo

2.1 Objetivo geral

O objetivo geral deste trabalho é desenvolver e documentar um protótipo de sistema de Inteligência Artificial para avaliação de risco de inundação no bairro do Butantã, combinando classificadores baseados em chuva com dados reais de ocorrências de alagamento, utilizando apenas dados públicos e ferramentas de código aberto.

2.2 Objetivos específicos

De forma mais detalhada, os objetivos específicos do projeto são:

Construir uma série histórica diária de chuva (2020–2025) para o posto CGE Butantã a partir das planilhas oficiais disponibilizadas pelo CGE-SP.

Definir faixas de chuva diária que representem três classes de risco local: Sem risco, Risco de Inundação Transitável e Risco de Inundação Intransitável.

Treinar modelos de classificação (Regressão Logística e Random Forest) para aprender essas três classes a partir de chuva e lags, disponibilizando o resultado em um aplicativo Streamlit.

Integrar dados de ocorrências de alagamento do GeoSampa (camada risco_ocorrencia_alagamento) com a chuva do CGE Butantã, gerando uma série de “dias com evento” e “dias sem evento” para a Subprefeitura do Butantã.

Desenvolver um segundo modelo binário para “alarme de alagamento em dias chuvosos”, com engenharia de atributos (lags, acumulados, índice API) e oversampling, de forma a atenuar o desbalanceamento extremo entre dias com e sem alagamento.

Discutir criticamente as limitações de dados, a dificuldade física de prever alagamentos e propor caminhos futuros de melhoria, incluindo novas bases de dados, ajustes de limiares e experimentação de modelos mais avançados.

3. Fundamentos teóricos

3.1 Inundações urbanas, drenagem e previsibilidade

Inundações urbanas ocorrem quando o escoamento superficial de água de chuva excede a capacidade de infiltração do solo e/ou a capacidade de escoamento do sistema de drenagem, composto por galerias, bocas de lobo, canais e rios urbanos. Em áreas densamente urbanizadas como o Butantã, a alta proporção de superfícies impermeáveis (asfalto, calçadas, lajes e telhados), somada a redes de drenagem subdimensionadas ou malconservadas, favorece o acúmulo rápido de água nas vias e nas depressões topográficas.

Não existe, portanto, uma relação simples do tipo “chove X mm $\Rightarrow$ alaga”. A resposta hidráulica depende da capacidade das galerias, da obstrução por lixo e folhas, da topografia local que concentra ou dispersa o fluxo, da manutenção periódica dos dispositivos de drenagem e da ocupação de fundos de vale e margens de córregos. Por essa razão, muitos estudos utilizam abordagens híbridas, combinando modelos hidrológicos e hidráulicos com modelos estatísticos ou de aprendizado de máquina, que aprendem padrões a partir de séries históricas de chuva e impacto.

No presente trabalho, por limitação de dados e de escopo, optou-se por uma abordagem puramente estatística de aprendizado supervisionado aplicada a séries temporais de chuva e registros de alagamento, com ênfase no caráter exploratório e didático do protótipo.

3.2 Intensidade de chuva, limiares e classes de risco

Órgãos de meteorologia, como o INMET, classificam a intensidade de chuva com base em intervalos de acumulados horários ou diários. De forma simplificada, chuvas fracas tendem a apresentar acumulados baixos e pouco impacto, enquanto chuvas moderadas a fortes se situam na faixa de 20–50 mm/dia, e chuvas muito fortes ou extremas frequentemente superam 60–70 mm em 24 horas, estando associadas a impactos significativos em áreas urbanas.

Estudos de precipitação extrema no Brasil mostram que o percentil 90 de chuva diária (eventos intensos) costuma situar-se entre 20 e 40 mm em diversas regiões, enquanto o

percentil 99 (eventos muito extremos) muitas vezes supera 60–70 mm/dia. Em grandes cidades, trabalhos que relacionam chuva e impactos urbanos indicam limiares nessa ordem de grandeza para a ocorrência de alagamentos e outros danos, reforçando a ideia de que acumulados acima de 60 mm em 24 horas são situações críticas do ponto de vista do risco.

A partir dessa literatura e de classificações adotadas por órgãos oficiais, foram definidas, neste projeto, as seguintes faixas de risco para o Butantã:

Classe 0 – Sem risco: chuva em 24h < 20 mm;

Classe 1 – Risco de Inundação Transitável: $20 \text{ mm} \leq \text{chuva em 24h} < 60 \text{ mm}$;

Classe 2 – Risco de Inundação Intransitável: chuva em 24h $\geq 60 \text{ mm}$.

Esses limiares não significam que todo dia com 60 mm irá necessariamente produzir uma inundação intransitável, mas funcionam como um indicador de severidade razoável para uso em sistemas de alerta de risco, alinhado a práticas de classificação de eventos extremos em contexto urbano.

3.3 Dados pluviométricos, séries temporais e índice API

A precipitação é medida em milímetros (mm), representando a altura da lâmina de água acumulada sobre uma superfície. Neste trabalho foi utilizada a chuva acumulada em 24 horas, registrada diariamente pelo posto do CGE Butantã entre 2020 e 2025. Apenas a chuva do dia, porém, não é suficiente para explicar o risco de inundação, já que a resposta hidrológica depende também da chuva antecedente e do grau de saturação do solo e do sistema de drenagem.

Por esse motivo, a literatura frequentemente emprega atributos derivados da série temporal, como lags de 1, 2 e 3 dias de chuva (chuva_lag1, chuva_lag2, chuva_lag3), acumulados móveis em janelas de 3, 7 e 30 dias (acum_3d, acum_7d, acum_30d) e índices agregados como o API (Antecedent Precipitation Index). O API é calculado recursivamente e busca sintetizar a chuva antecedente com um fator de decaimento exponencial:

$$\text{API}_t = k \cdot \text{API}_{(t-1)} + P_t$$

em que P_t é a chuva do dia e $0 < k < 1$ é um fator de persistência. Neste trabalho, adotou-se $k = 0,9$ como valor de referência, compatível com aplicações em solos com resposta intermediária. O objetivo não é representar com exatidão o comportamento físico da bacia, mas sim fornecer ao modelo de Inteligência Artificial um indicador simples de saturação antecedente.

3.4 Algoritmos de aprendizado de máquina: Regressão Logística e Random Forest

Para os problemas de classificação abordados, foram escolhidos dois algoritmos clássicos amplamente usados em aplicações hidrológicas e ambientais: a Regressão Logística e a Random Forest.

A Regressão Logística modela a probabilidade de uma classe como uma função logística dos atributos de entrada. No caso binário, a probabilidade de $Y = 1$ é dada por:

$$P(Y = 1 | x) = 1 / (1 + e^{-(\beta_0 + \beta^T x)})$$

onde x é o vetor de atributos (chuva, lags, acumulados, calendário etc.) e β é o vetor de coeficientes ajustado pelo treinamento. Para mais de duas classes, como no modelo de três níveis de risco, utiliza-se a versão multinomial (softmax). A principal vantagem da Regressão Logística é ser um modelo relativamente simples, interpretável e robusto com poucos dados, servindo como boa linha de base para comparação.

A Random Forest, por sua vez, é um método de ensemble baseado em múltiplas árvores de decisão. Cada árvore é treinada a partir de uma amostra bootstrap do conjunto de treino (técnica conhecida como bagging), e, a cada divisão, é considerada apenas uma amostra aleatória de atributos. Essa combinação de amostragem de dados e de variáveis aumenta a diversidade das árvores individuais e melhora a generalização do conjunto. A Random Forest costuma apresentar boa performance sem grande esforço de ajuste de hiperparâmetros, captura relações não lineares entre variáveis e é relativamente robusta a ruídos. Diversos trabalhos de mapeamento de suscetibilidade a inundações utilizam Random Forest com sucesso em bacias urbanas.

3.5 Desbalanceamento de classes e oversampling

Um desafio central do modelo binário de alarme de alagamento é o desbalanceamento extremo entre dias com e sem evento. Na série de 2020 a 2025, obtida a partir da união de chuva do CGE e ocorrências do GeoSampa, há cerca de 2131 dias com registro de chuva, mas apenas aproximadamente 10 dias com ocorrência registrada de alagamento na Subprefeitura do Butantã. Isso significa que a classe positiva (evento) é raríssima em comparação com a classe negativa (sem evento).

Se um modelo for treinado diretamente sobre essa distribuição, ele tende a aprender a estratégia trivial de sempre prever “sem alagamento”, obtendo uma acurácia aparentemente alta, porém com recall zero para a classe de interesse. Para atenuar esse

problema, empregou-se o oversampling da classe minoritária apenas no conjunto de treino. A ideia é replicar, com reposição, os poucos exemplos positivos até que eles representem uma fração mais razoável do conjunto de treinamento (por exemplo, 20%), aumentando a chance de o modelo aprender padrões associados a esses casos raros. Trata-se de uma solução simples, mas eficaz como primeiro passo em cenários com desbalanceamento extremo.

4. Materiais e Métodos

4.1 Área de estudo

A área de estudo é a Subprefeitura do Butantã, localizada na Zona Oeste da cidade de São Paulo. A região combina áreas predominantemente residenciais, grandes eixos viários e importantes instituições, como a Universidade de São Paulo (USP), que influenciam tanto a dinâmica de tráfego quanto a drenagem urbana. Para o propósito deste projeto, o Butantã foi tratado como uma única unidade de risco, ligada a um único posto pluviométrico do CGE e a um conjunto de pontos de alagamento georreferenciados.

4.2 Fontes de dados

Apesar de existirem mais fontes de dados que comportam o escopo do projeto, apenas duas fontes oficiais de dados foram utilizadas como base do projeto: o CGE-SP para chuva e o GeoSampa para ocorrências de alagamento. Isso se deve à falta de consistência, padronização e em muitos casos a ausência completa de dados no dataset disponibilizado pela plataforma.

No caso da chuva, a fonte institucional é o Centro de Gerenciamento de Emergências Climáticas da Prefeitura de São Paulo (CGE-SP), que disponibiliza planilhas com registros pluviométricos diários. Foi utilizado, em particular, um arquivo tratado no projeto, contendo os dados de 2020 a 2025 para o posto “BUTANTA_2020_2025”. A planilha apresenta colunas de ano, mês (em português) e posto, acompanhadas por colunas de dias de 1 a 31 com os acumulados diários de chuva em milímetros.

As ocorrências de alagamento foram obtidas a partir do Portal GeoSampa, sistema de informações geográficas da Prefeitura de São Paulo. Utilizou-se o serviço WFS do GeoSampa, acessando a camada “geoportal: risco_ocorrendia_alagamento”. Essa camada contém, dentre outros campos, a data da ocorrência (dt_ocorrendia), o nome da subprefeitura (nm_subprefeitura) e a geometria do ponto (geometry). Neste trabalho, a geometria não foi explorada em profundidade, já que os dados contidos no dataset não

eram consistentes o suficiente, mas a informação de subprefeitura foi essencial para filtrar os registros associados ao Butantã.

4.3 Pré-processamento da chuva (CGE Butantã)

O pré-processamento da chuva foi implementado em Python, utilizando a biblioteca pandas. Inicialmente, o arquivo Excel é lido com `read_excel`, especificando a aba referente ao Butantã. Como o mês está escrito em texto (Jan, Fev, Mar, etc.), é feito um mapeamento para números inteiros, criando-se uma coluna `MesNum`. Em seguida, as colunas de dias, numeradas de 1 a 31, são identificadas e “derretidas” (função `melt`) para transformar a matriz original em uma tabela longa, em que cada linha corresponde a um dia específico.

A partir das colunas de ano, mês numérico e dia, é construída uma coluna `data` com tipo de data (`datetime`), tratando possíveis datas inválidas. Linhas com `data` ou `chuva_mm` nulos são descartados, e o dataframe resultante é ordenado cronologicamente. Essa etapa gera uma série temporal diária de chuva (`df_long`) com as colunas `data` e `chuva_mm`, contendo cerca de 2131 dias entre 2020 e 2025.

4.4 Dataset do modelo de 3 classes (risco por chuva)

A partir da série diária de chuva, foi montado o dataset para o modelo de três classes de risco. Primeiramente, cada valor de `chuva_mm` é mapeado para uma classe inteira (`classe_risco`) usando a função de classificação definida com os limiares de 20 e 60 mm. Em seguida, a tabela é indexada pela coluna de `data` e ordenada.

Para incorporar informação temporal, são calculados os lags de um, dois e três dias de chuva (`chuva_lag1`, `chuva_lag2`, `chuva_lag3`), por meio da função `shift`. Também são acrescentadas variáveis de calendário, como o mês (`mes`) e o dia da semana (`dia_semana`, em que 0 representa segunda-feira). As primeiras linhas, que não possuem lags completos, são removidas.

O resultado é um conjunto de dados (`df_ml`) contendo as principais colunas de entrada, como `chuva_mm`, `chuva_lag1`, `chuva_lag2`, `chuva_lag3`, `mes` e `dia_semana`, além da coluna de saída `classe_risco`. Esse dataset foi utilizado para treinar os modelos de classificação de risco baseados na chuva.

4.5 Construção das labels com ocorrência de alagamento (GeoSampa + CGE)

Para criar um rótulo de “dia com alagamento” ou “dia sem alagamento” no Butantã, implementou-se um script em Python que integra a série de chuva do CGE com as ocorrências do GeoSampa. Primeiro, a mesma função de leitura da chuva é utilizada para obter a série diária de 2020 a 2025. Em seguida, o serviço WFS do GeoSampa é chamado para obter a camada de alagamentos, que é carregada em um GeoDataFrame com a biblioteca geopandas.

Inspecionando as colunas, identifica-se `nm_subprefeitura` como campo adequado para filtrar registros do Butantã. O filtro é feito por substring, ignorando maiúsculas/minúsculas, resultando em um subconjunto de cerca de 13 registros de alagamento associados à Subprefeitura do Butantã. A coluna de data (`dt_ocorrencia`) é convertida para formato de data, e as ocorrências são agregadas por dia, obtendo-se uma contagem de eventos (`n_eventos`) e uma flag booleana (`flag_evento`) indicando se houve pelo menos um alagamento naquele dia.

Por fim, essa tabela de eventos diários é mesclada com a série de chuva, usando a data como chave. Dias sem alagamento explícito recebem `n_eventos = 0` e `flag_evento = 0`. O resultado é um arquivo CSV com as colunas `data`, `chuva_mm`, `n_eventos` e `flag_evento`, com uma linha por dia ao longo do período analisado.

4.6 Filtragem para dias chuvosos e features do modelo binário

Com a tabela integrada de chuva e alagamentos em mãos, prepara-se o dataset para o modelo binário. Como o objetivo é avaliar o risco de alagamento em dias razoavelmente chuvosos, adota-se um limiar mínimo de chuva, por exemplo, 5 mm em 24 horas. São, então, selecionados apenas os dias com `chuva_mm ≥ 5`.

Sobre esse subconjunto, são calculadas features adicionais semelhantes às utilizadas no modelo de três classes, porém de forma mais completa: lags de 1, 2 e 3 dias, acumulados em janelas de 3, 7 e 30 dias e o índice API. Também são adicionadas variáveis de calendário (`ano`, `mes`, `dia`, `dia_semana`). Assim como antes, as primeiras linhas, que não possuem lags ou acumulados completos, são descartadas para evitar valores nulos.

Depois dessa etapa, obtém-se um conjunto com cerca de 394 dias chuvosos, dos quais apenas 7 possuem `flag_evento = 1`. Essa base é então dividida em treino e teste,

tipicamente em 70% e 30%, respeitando a ordem temporal quando possível, de forma a simular uma situação de previsão futura baseada em dados passados.

4.7 Oversampling e treino dos modelos binários

No conjunto de treino, o número de dias com alagamento é muito pequeno em comparação ao número de dias sem evento. Para enfrentar esse desbalanceamento, aplica-se oversampling da classe positiva. Na prática, contam-se os exemplos de cada classe e define-se uma proporção alvo de positivos (por exemplo, 20%). A partir disso, determinam-se quantas cópias (com reposição) dos exemplos positivos são necessárias para atingir essa proporção no conjunto de treinamento.

Com o treino balanceado, são ajustados novamente dois modelos: uma Regressão Logística e uma Random Forest, agora em configuração binária. O conjunto de teste permanece com a distribuição real, ou seja, poucos eventos e muitos dias sem alagamento. Isso permite avaliar o comportamento dos modelos em um cenário realista, em que qualquer acerto de um dia com evento já é valioso.

5. Discussão

5.1 Por que dois modelos?

A existência de dois modelos no projeto não é redundante, mas reflete duas perguntas diferentes sobre o problema. O modelo de três classes, baseado em faixas de chuva, responde a uma questão mais geral: “dado o acumulado de chuva em 24 horas, qual é o nível de risco de inundação?”. Essa abordagem opera com a chuva como proxy de severidade e não depende de registros de alagamento, que são raros. Ela organiza o conhecimento climatológico em uma régua operacional de risco, útil inclusive quando não há dados de impacto.

Já o modelo binário parte de uma pergunta mais específica: “entre os dias com chuva, quais dias efetivamente tiveram alagamento registrado no Butantã?”. Essa abordagem utiliza explicitamente os dados de eventos do GeoSampa e tenta capturar padrões de chuva (incluindo a chuva antecedente) que diferenciam dias com e sem alagamento. Por lidar diretamente com impacto, é o modelo mais interessante do ponto de vista de prevenção, mas também o mais limitado pela escassez de dados e pela complexidade do fenômeno.

A combinação dos dois modelos cria uma visão em camadas: o modelo de três classes funciona como uma primeira avaliação de severidade da chuva, enquanto o modelo binário

é um experimento mais ousado, que tenta se aproximar do risco real de evento, ainda que com resultados incompletos.

5.2 Dificuldade intrínseca de prever alagamentos

A discussão dos resultados evidencia o quão difícil é prever alagamentos urbanos a partir apenas de chuva. Cidades como São Paulo apresentam aumento de episódios de chuva extrema, mas nem toda chuva extrema gera alagamentos em todos os bairros, e nem todo alagamento está associado a um grande acumulado diário. Fatores como manutenção da drenagem, lixo nas ruas, obras recentes e ocupação irregular introduzem uma variabilidade que não está presente nas séries de chuva.

Do ponto de vista da Inteligência Artificial, isso significa que o modelo está enxergando apenas uma parte da realidade. Ele “vê” a chuva, e eventualmente variáveis derivadas como lags e API, mas não tem acesso aos estados internos da infraestrutura. Assim, mesmo que se disponha de muitos anos de dados de chuva, a capacidade do modelo de antever eventos específicos pode continuar limitada. O protótipo desenvolvido neste trabalho assume essa limitação de forma explícita e busca, em vez de resolver o problema por completo, organizar o raciocínio em torno de faixas de risco e de assinaturas de chuva que antecedem alguns poucos eventos.

5.3 Ganhos e limitações dos resultados

No modelo de três classes, os resultados quantitativos são bastante satisfatórios. Em testes de validação temporal, a Regressão Logística e, principalmente, a Random Forest apresentaram acurácias próximas de 100%, com matrizes de confusão praticamente diagonais. Isso indica que os modelos conseguiram reaprender de forma muito precisa os limiares de 20 e 60 mm estabelecidos a priori. Em outras palavras, o classificador funciona como uma implementação formal da régua de severidade que o próprio grupo definiu, com a vantagem de poder ser expandido futuramente com novos atributos sem alterar a lógica básica de classificação.

Em contraste, o modelo binário condicionado a dias chuvosos, mesmo após filtragem e oversampling, ainda apresenta desempenho limitado na classe de interesse. A acurácia global é alta, porque a maioria dos dias é de fato “sem evento”, mas o recall da classe de alagamento permanece baixo. Em algumas execuções, a Regressão Logística consegue identificar parte dos poucos dias com alagamento no conjunto de teste, enquanto a Random Forest tende a adotar uma postura mais conservadora, prevendo quase sempre a classe negativa.

Esses resultados mostram que o modelo binário deve ser encarado como uma prova de conceito, ilustrando tanto o potencial quanto os limites da abordagem. O fato de ele ser capaz de “tocar” alguns dias com evento após o oversampling já é uma melhoria em relação ao cenário inicial, no qual a classe positiva era simplesmente ignorada pelo algoritmo.

5.4 Dados adicionais que poderiam melhorar a acurácia

A análise das limitações do modelo binário deixa claro que a melhoria da acurácia passa por ampliar e enriquecer as bases de dados, tendo em vista que as bases de dados públicas são extremamente deficitárias.

Do ponto de vista temporal, o ideal seria trabalhar com séries mais longas de ocorrências de alagamento, abrangendo períodos maiores que cinco anos, a fim de aumentar o número de exemplos positivos. Em termos de modelagem, técnicas de oversampling mais sofisticadas, como o SMOTE, modelos de gradient boosting e redes neurais recorrentes específicas para séries temporais poderiam ser testados. Também é possível ajustar limiares de decisão dos classificadores para aumentar o recall da classe de evento, aceitando mais falsos positivos, o que faz sentido em um contexto de proteção à vida.

5.5 Aspectos didáticos e narrativos do projeto

Além dos resultados numéricos, o projeto tem um valor importante como estudo de caso para o estudo da Inteligência Artificial. Ele mostra, de forma concreta, o que significa pegar uma ideia de alto nível (“usar Inteligência Artificial para prever enchentes”) e traduzi-la em etapas de coleta, pré-processamento, modelagem, validação e implementação. O recorte espacial para o Butantã demonstra a importância de delimitar bem o problema, para que o escopo seja viável em termos de dados e tempo.

O trabalho também evidencia o “choque de realidade” entre a expectativa de alto desempenho da Inteligência Artificial e as limitações práticas impostas pela disponibilidade de dados. Ao expor claramente que existem apenas alguns dias com alagamento em cinco anos de série, o projeto demonstra maturidade em apontar que o problema não pode ser resolvido apenas com algoritmos, mas depende de políticas públicas de monitoramento e de infraestrutura. Por fim, a construção de um protótipo funcional em Streamlit contribui para aproximar o projeto do ambiente acadêmico, permitindo que outros estudantes e professores interajam com o sistema e visualizem o risco estimado em diferentes cenários de chuva.

6. Encerramento

Conclui-se que o projeto apresentou o desenvolvimento de um protótipo de Inteligência Artificial para avaliação de risco de inundação no bairro do Butantã, combinando duas abordagens complementares: um classificador de três classes de risco baseado na intensidade de chuva diária e um modelo binário condicionado a dias chuvosos, que utiliza dados reais de ocorrências de alagamento. Ambos foram implementados com ferramentas de código aberto, integrados em protótipos web simples e documentados de forma a deixar claro tanto os acertos quanto as limitações deles.

Do ponto de vista quantitativo, o modelo de três classes demonstrou excelente desempenho ao reproduzir a lógica de faixas de chuva definidas com base em referências da literatura e de órgãos oficiais. Já o modelo binário evidenciou o impacto da escassez de dados de alagamento na capacidade preditiva da Inteligência Artificial, mesmo após a aplicação de oversampling e de uma engenharia de atributos cuidadosa. Isso reforça a ideia de que, sem dados suficientes e detalhados, algoritmos sofisticados não são capazes de compensar lacunas fundamentais da base de conhecimento.

Do ponto de vista conceitual, o projeto reforça que prever alagamentos urbanos não é apenas um problema de modelagem estatística, mas uma questão interdisciplinar que envolve hidrologia, engenharia, planejamento urbano e gestão de infraestrutura. Ainda assim, protótipos como o apresentado aqui são importantes porque ajudam a organizar o problema, testar hipóteses, definir limiares operacionais e sinalizar quais dados adicionais seriam mais valiosos para futuros aprimoramentos.

Como trabalhos futuros, sugerem-se a ampliação da série histórica de alagamentos, a experimentação de novos algoritmos de aprendizado de máquina e, idealmente, a conexão do protótipo com APIs de previsão de chuva em tempo quase real. Com isso, o sistema poderia evoluir de uma ferramenta retrospectiva de análise para um componente de um eventual sistema de alerta local de risco de inundação.

Referências

ANDRADE, Jackeline Soares. Eventos extremos de precipitação pluvial na cidade de Itacoatiara-AM. 2023. Dissertação (Mestrado em Geografia) – Universidade Federal do Amazonas, Manaus, 2023. Disponível em: <https://tede.ufam.edu.br/bitstream/tede/9467/5/DISS_JackelineAndrade_PPGEOG.pdf>. Acesso em: 23 nov. 2025.

DUARTE, Cristiana Coutinho. Eventos extremos de chuva e análise da suscetibilidade a movimentos de massa e inundações na Região Metropolitana do Recife. 2016. Tese (Doutorado em Geografia) – Universidade Federal de Pernambuco, Recife, 2016. Disponível em: <https://repositorio.ufpe.br/bitstream/123456789/16971/1/TESE_VERS%C3%83O%20FINAL_CRISTIANA%20COUTINHO%20DUARTE_GEOGRAFIA_BIBLIOTECA.%2025%20jan.%202016.pdf>. Acesso em: 23 nov. 2025.

GONÇALVES, B. H. Estudo de episódios extremos de chuva e impactos urbanos. Referido em: DUARTE, C. C. (2016).

MARTINS, Alessandro Marques. Determinação de limiares de precipitações extremas na bacia do rio Sapucaí. Revista Brasileira de Geomorfologia, v. 19, n. 3, p. 547–561, 2018. Disponível em: <<https://www.abge.org.br/downloads/rev-DETERMINACAO%20DE%20LIMIARES.pdf>>. Acesso em: 23 nov. 2025.

NOBOA, Caique Salvador. Engenharia de features para construção de um modelo de previsão de eventos hidrometeorológicos em Curitiba. 2023. Trabalho de Conclusão de Curso – Universidade Tecnológica Federal do Paraná, Curitiba, 2023. Disponível em: <<https://riut.utfpr.edu.br/jspui/bitstream/1/35538/1/previsao.pdf>>. Acesso em: 23 nov. 2025.

SILVA, Luiz Felipe da. Aplicação de algoritmos de aprendizado de máquina para o mapeamento de suscetibilidade a inundações da bacia hidrográfica do Rio Itajaí. 2025. Trabalho de Conclusão de Curso – Universidade Federal de Santa Catarina, Florianópolis, 2025. Disponível em: <https://repositorio.ufsc.br/bitstream/handle/123456789/266382/TCC_LuizFelipeDaSilva.pdf>. Acesso em: 23 nov. 2025.

MAKITA, F. H. Mapeamento de suscetibilidade a inundação usando modelo Random Forest. São José dos Campos: INPE, 2023. Disponível em: <https://marte2.sid.inpe.br/col/sid.inpe.br/marte2/2023/04.25.10.50/doc/156263_compressed.pdf>. Acesso em: 23 nov. 2025.

PENNA, Ana Caroline. Extremos de chuva na cidade de São Paulo. 2020. Dissertação – INPE, São José dos Campos, 2020. Disponível em: <<https://mtc-m21c.sid.inpe.br/col/sid.inpe.br/mtc-m21c/2020/07.08.18.51/doc/Ana%20Caroline%20Penna.pdf>>. Acesso em: 23 nov. 2025.

PORTAL MULTIPLIX. Meteorologista do Inmet explica como classificar a intensidade das chuvas. 2021. Disponível em: <<https://www.portalmultiplix.com/noticias/cotidiano/meteorologista-do-inmet-explica-como-classificar-a-intensidade-das-chuvas>>. Acesso em: 23 nov. 2025.

PREFEITURA DO MUNICÍPIO DE SÃO PAULO. Centro de Gerenciamento de Emergências Climáticas – CGE-SP. Disponível em: <<https://www.cgesp.org/>>. Acesso em: 23 nov. 2025.

PREFEITURA DO MUNICÍPIO DE SÃO PAULO. GeoSampa – Sistema de informações geográficas. Metadados da camada de alagamentos. Disponível em: <<https://metadados.geosampa.prefeitura.sp.gov.br/geonetwork>>. Acesso em: 23 nov. 2025.

PREFEITURA DO RIO DE JANEIRO; FUNDAÇÃO CEPERJ. Inundação: dimensionamento, alternativas tecnológicas, políticas públicas e estudos afins na prevenção e controle. Rio de Janeiro: CEPERJ, 2014.

TERRA / BBC News Brasil. Porque chuvas em São Paulo têm provocado tantos estragos. 13 mar. 2025. Disponível em: <<https://www.terra.com.br/noticias/brasil/por-que-chuvas-em-sao-paulo-tem-provocado-tantos-estragos>>. Acesso em: 23 nov. 2025.